

Bluff Detect - detekcija blefiranja u Texas Hold'em pokeru

Definicija problema

Automatsko utvrđivanje da li je potez igrača u Texas Hold'em pokeru blef (agresivan potez sa objektivno slabom rukom), na osnovu podataka o toku ruke, ulogama, poziciji igrača i stanju karata na stolu. Problem se sastoji u tome da se na osnovu dostupnih informacija predvidi da li igrač ulaže sa slabom rukom radi obmane protivnika. Zadatak protivnika je da, analiziranjem istorijskih poker ruku i obrazaca ponašanja igrača, napravi model koji pouzdano predviđa pojavu blefa i izdvoji karakteristike koje najviše utiču na to da određeni potez bude klasifikovan kao blef.

Motivacija

Predložena metodologija zasniva se na primeni tehnika nadgledanog učenja nad istorijskim podacima No-Limit Texas Hold'em poker ruku, sa ciljem detekcije blefa i analize potencijalne uspešnosti blefirajućih poteza. Metodologija je inspirisana i metodološki utemeljena na radovima navedenim u relevantnoj literaturi, posebno radu Razvana Rance [1], koji pokazuje da se blef ne može pouzdano identifikovati samo na osnovu jačine ruke, već zahteva analizu kontekstualnih karakteristika igre.

Relevantna literatura

[1] Razvan Rance, School of Informatics, University of Edinburgh (2013). Identifying Features for Bluff Detection in No-Limit Texas Hold'em. <https://cdn.aai.org/ocs/ws/ws1038/7109-30520-1-PB.pdf>

Korišćeni algoritmi:

Nije specificirano koji algoritmi su korišćeni, ali se spominje poređenje performansi sa više klasifikatora.

Tema rada:

Istraživanje kako različite karakteristike utiču na mogućnost detekcije blefa u No-Limit Texas Hold'em pokeru. Cilj je identifikovati koje se informacije najviše uklapaju sa situacijama koje se mogu klasifikovati kao blef.

Skup podataka:

376.000 odigranih ruku iz No-Limit Texas Hold'em turnira. Podaci su filtrirani da uklone situacije gde je očigledno da igrač ima jaču ruku.

Evaluacija:

Rešenje je evaluirano poređenjem performansi klasifikatora nad različitim skupovima karakteristika, pri čemu je kao glavna metrika korišćen AUC (Area under the ROC Curve). Time model razlikuje blef i ne-blef situacije nezavisno od praga odlučivanja.

Rezultati:

Identifikovano je da se određene karakteristike (pozicija u igri, iznos pota, snaga flopa itd.) statistički značajno razlikuju između blefova i normalnih poteza. Kombinovanjem karakteristika je moguće klasifikovati situacije sa dobrom preciznošću kod nekih agenata, što znači da su te karakteristike korisne za prepoznavanje blefa. Ove karakteristike mogu pomoći agentima da bolje modeluju protivnike i njihovu strategiju, ali da dalji rad na boljim modelima može poboljšati preciznost detekcije blefa.

Rad je relevantan za naš projekat jer pokazuje da se blef ne može detektovati samo na osnovu jačine ruke, već zahteva pažljivo odabrane karakteristike koje opisuju kontekst igre. U našem projektu preuzimamo ideju kontekstualnih karakteristika (pozicija, veličina pota, faza igre), ali ćemo koristiti savremenije klasifikacione modele i jasnije definisati proceduru evaluacije. Ograničenje rada je što se ne razmatra dugoročno ponašanje pojedinačnih igrača, već se blef posmatra na nivou pojedinačnih situacija. Takođe, korišćeni klasifikatori nisu detaljno opisani, što otežava reprodukciju rezultata.

[2] Tarik Začiragić, Aske Plaak K., Joost Batenburg, LIACS, Leiden University (2025). Analysis of Bluffing by DQN and CFR in Leduc Hold'em Poker.

<https://arxiv.org/html/2509.04125>

Korišćeni algoritmi:

- Deep Q-Networks - model slobodnog učenja pojačanjem koji uči politiku kroz Q-funkciju i nagrade
- Counterfactual Regret Minimization (CFR) - algoritam iz teorije igara za približno računanje Nash-ekvilibrija u igrama ne potpune informacije.

Tema rada:

Istraživanje da li i kako algoritmi poput DQN i CFR pokazuju ponašanje blefa u Leduc Hold'em (pojednostavljena verzija pokera) kada se treniraju i evaluiraju.

Skup podataka:

Simulirano okruženje Leduc Hold'em, gde su DQN i CFR agenti igrali oko 100.000 ruku jedan protiv drugog kako bi se sakupili podaci o akcijama.

Evaluacija:

Evaluacija je izvršena analizom ponašanja agenata tokom simuliranih partija, pri čemu su merene učestalosti blefa, uspešnost blefirajućih poteza i ukupni učinak agenata. Umesto klasifikacionih metrika, korišćeni su statistički pokazatelji ponašanja i performansi u igri.

Rezultati:

Oba algoritma spontano razvijaju blefirajuće ponašanje, iako im nije eksplicitno uvedeno pravilo za blef. Učestalost i stil blefa se razlikuje: CFR agent koristi blef češće i raspoređuje ga na više ruku u okviru strategije, dok DQN agent blefira manje često, ali njegove blef strategije su selektivnije i koriste srednje slabe ruke na optimalnim mestima. Uspešnost blefa je slična za oba igrača (~34% - 39%).

Rezultati pokazuju da blefiranje nije toliko karakteristika specifičnog algoritma, već se javlja kao posledica optimalne strategije u Leduc Hold'em pokeru. Rad je relevantan za naš projekat jer potvrđuje da se blef može posmatrati kao probabilistička pojava zasnovana na obrascima ponašanja, što opravdava korišćenje klasifikacionih modela koji proizvode verovatnoće, a ne samo binarne odluke. Za razliku od ovoga, mi se fokusiramo na nadgledano učenje i detekciju blefa u stvarnim Texas Hold'em podacima, a ne na analizu emergentnog ponašanja agenata.

Ograničenja rada je korišćenje Leduc Hold'em igre, koja je znatno jednostavnija od stvarnog Texas Hold'em-a, pa se rezultati ne mogu direktno preneti na realne poker scenarije.

[3] Jiahui Xu, Jing Chen, Shaofei Chen, College of Intelligence Science and Technology (2021). Efficient Opponent Exploitation in No-Limit Texas Hold'em Poker: A Neuroevolutionary Method Combined with Reinforcement Learning.

<https://www.mdpi.com/2079-9292/10/17/2087>

Korišćeni algoritmi:

Reinforcement Learning (RL) u kombinaciji sa neuroevolucijom (NE) za treniranje agenata koji uče iz celokupnih epizoda igre, kao i mehanizmi "experience replay" i "fitness evaluacije" cele ruke za poboljšanje performansi modela u složenim situacijama.

Tema rada:

Rad predlaže kombinaciju neuroevolucije i reinforcement learning-a za efikasno modelovanje i eksploataciju protivnika u No-Limit Texas Hold'em-u. Fokus je na učenju strategija koje prilagođavaju ponašanje protivnika, uključujući i obrasce agresivnog blefiranja koje treba iskoristiti.

Skup podataka:

Simulacija No-Limit Texas Hold'em partija sa različitim tipovima protivnika koristeći RL trening radi generisanja strategija i evaluacije modela.

Evaluacija:

Rešenje je evaluirano poređenjem performansi predloženog modela sa osnovnim RL i NE pristupima, pri čemu je kao metrika korišćen win-rate i ukupna profitabilnost agenata u simuliranim partijama.

Rezultati:

Metod nadmašuje pojedinačne RL i NE pristupe, pokazujući da kombinovani model bolje iskorišćava obrasce protivnika i adaptira se na agresivnije ili nepredvidive strategije, što je važno za predikciju i eksploataciju blefa.

U našem projektu nećemo koristiti reinforcement learning, već ćemo se fokusirati na analizu istorijskih podataka i klasifikaciju blefa, ali ćemo preuzeti ideju korišćenja kontekstualnih informacija i ponašanja protivnika kao ključnih ulaznih atributa.

Rad se oslanja isključivo na simulirane protivnike, pa nije jasno kako bi se metod ponašao u realnim podacima sa ljudskim igračima.

Skup podataka

U okviru ovog projekta koristiće se tri skupa podataka koji imaju različite uloge u rešavanju definisanog problema.

1. Poker Hands Dataset (Kaggle)

Ovaj skup podataka sadrži million zapisa poker ruku opisanih kombinacijama karata, pri čemu je svaka ruka klasifikovana u jednu od deset standardnih poker kategorija (high card, pair, two pairs, three of a kind, straight, flush, full house, four of a kind, straight flush i royal flush).

Svaki zapis u skupu podataka sadrži informacije o pet karata (znak i rang karte), dok ciljno obeležje predstavlja klasu poker ruke. Problem koji se rešava nad ovim skupom podataka je višeklasna klasifikacija, gde je cilj naučiti model koji na osnovu karata pouzdano određuje jačinu ruke.

Ovaj skup podataka ne sadrži informacije o toku igre, akcijama igrača, veličinama uloga ili poziciji za stolom, te se ne koristi direktno za detekciju blefa. Koristi se za treniranje modela za procenu jačine ruke, odnosno za dobijanje objektivne informacije o snazi karata, nezavisno od ponašanja igrača.

[2. Poker Hand History Dataset](#)

Drugi, glavni skup podataka u projektu je Poker Hand History Dataset (PHH), koji sadrži istorijske zapise No-Limit Texas Hold'em poker partija i obuhvata detaljne informacije o toku svake ruke, uključujući sekvencu akcija igrača (check, call, bet, raise, fold), faze igre (pre-flop, flop, turn i river), veličine uloga i pota, poziciju igrača za stolom, kao i privatne i zajedničke karte.

Za razliku od Kaggle skupa podataka, PHH dataset omogućava analizu konteksta igre i ponašanja igrača, što je ključno za rešavanje problema detekcije blefa. Svaki zapis predstavlja pojedinačnu odluku igrača u okviru ruke, zajedno sa relevantnim kontekstualnim informacijama.

[3. Online Poker Games Dataset](#)

Svaki zapis u datasetu opisuje ponašanje jednog igrača u okviru jedne ruke i sadrži informacije o kontekstu igre, uključujući identifikatore turnira i stola, veličinu stola (broj igrača), nivo igre, poziciju igrača (BTN, SB, itd.), kao i njegov stack (broj čipova). Pored toga, dataset beleži sekvencu akcija kroz sve faze igre (pre-flop, flop, turn, river), uključujući poteze kao što su fold, bet, call i raise. Dataset takođe sadrži informacije o kartama igrača i zajedničkim kartama na stolu, kao i konačnu poker kombinaciju koju je igrač formirao. Finansijski aspekt igre predstavljen je kroz vrednosti pota po fazama igre, uloge (betove), ante i blindove, kao i konačan rezultat ruke (dobitak ili gubitak).

Za razliku od standardnih skupova podataka koji se fokusiraju isključivo na klasifikaciju jačine ruke, ovaj dataset omogućava detaljnu analizu ponašanja igrača u realnim uslovima igre.

Ciljno obeležje i povezivanje skupova podataka

Ciljno obeležje u glavnom delu projekta je indikator blefa, koji ima binarne vrednosti:

- 1 (blef) – agresivan potez (bet ili raise) u situaciji kada igrač ima objektivno slabu ruku,
- 0 (ne-blef) – potez koji ne ispunjava uslove blefa.

Labele blefa nisu date u PHH skupu podataka, već će biti definisane kombinovanjem informacija o procenjenoj jačini ruke, fazi igre, i tipu odnosno veličini akcije.

Procena jačine ruke dobijena treniranjem modela nad Kaggle datasetom koristiće se kao dodatna ulazna karakteristika u modelu za detekciju blefa treniranom nad PHH skupom podataka. Na ovaj način se jasno razdvaja objektivna snaga ruke od ponašanja igrača u kontekstu igre, što omogućava precizniju i interpretabilniju detekciju blefirajućih poteza.

Metodologija

Primeniće se tehnike nadgledanog učenja za rešavanje problema detekcije blefa u No-Limit Texas Hold'em pokeru, u skladu sa pristupima opisanim u relevantnoj literaturi [1]. Metodologija je zasnovana na poređenju više standardnih klasifikacionih algoritama nad istim skupom podataka i istim skupom obeležja, kako bi se ispitalo koji modeli najbolje prepoznaju blefirajuće situacije. Kao osnovni modeli planirani su logistička regresija kao bazni (baseline) model, Naive Bayes, kao i ensemble pristupi poput Random Forest i Gradient Boosting modela.

Svi korišćeni modeli proizvode probabilistički izlaz, što omogućava interpretaciju rezultata u vidu verovatnoće da je posmatrani potez blef. Ovakav izlaz je pogodan za poređenje modela pomoću metrika kao što je AUC, kao i za kasniju analizu isplativosti blefirajućih poteza. Primenom više algoritama omogućava se direktno poređenje njihovih performansi i analiza uticaja različitih modela na uspešnost detekcije blefa.

Metod evaluacije

Za evaluaciju sistema korišćićemo standardne modele za procenu performansi u uslovima nauravnoteženih klasa (kao što je blef). Skup podataka biće podeljen na trening i test skup, pri čemu ćemo koristiti odnos 70% : 30%, a zatim ćemo primeniti k-fold unakrsnu validaciju (npr. za k=5). AUC metrika je verovatno najpogodnija za ovaj problem jer meri sposobnost modela da razlikuje blefirajuće i neblefirajuće poteze nezavisno od izbora praga odlučivanja. Pored nje, razmotrićemo i ostale metrike poput preciznosti, odziva, i F1-score-a.

Nakon računanja svih ovih mera, očekuje se da ćemo doneti jasne zaključke o uspešnosti detekcije blefa.

Tim

Aleksandra Balažević, R2-16/2025

Nemanja Šimšić, R2-18/2025

Luka Petković, R2-24/2025